3 часть расчетного, Корнеич Никита 20931

```
# Вариант 8
# Переменные: Iris versicolor, Длина чашелистика, Длина лепестка

# Открываем базу данных
df = pd.read_csv("iris.data", delimiter=',')
# Выбираем данные только с versicolor
df = df[df['class'].isin(['Iris-versicolor'])]

# Выбираем данные длины чашелистика и лепестка только с versicolor
length1 = df['lenght_of_petal']
length2 = df['lenght_of_sepal']
```

3.1. Проверить гипотезу о независимости переменных по критерию Хи-

квадрат

Используемые формулы:

Статистика критерия независимости χ^2 Пирсона

$$\chi_n^2 = n\sum_{i=1}^{s}\sum_{j=1}^{k}\frac{\left(\nu_{ij} - \nu_{i\bullet}\nu_{\bullet j} / n\right)^2}{\nu_{i\bullet}\nu_{\bullet j}} = n\left(\sum_{i=1}^{s}\sum_{j=1}^{k}\frac{\nu_{ij}^{\ 2}}{\nu_{i\bullet}\nu_{\bullet j}} - 1\right)$$

КОД ФУНКЦИИ:

```
def task1(len1, len2):
    # Разбиваем функцией из библиотеки pandas на 4 интервала
    # Теперь в len1 len2 хранятся интервалы в которых находятся длины
    len1 = pd.qcut(len1, 4)
    len2 = pd.qcut(len2, 4)

    # Создаем таблицу из двух столбцов длин
    df = pd.concat([len1, len2], axis=1)

    # Создаем таблицу с количеством пересекающихся интервалов
    table = pd.crosstab(df['lenght_of_petal'], df['lenght_of_sepal'])

    # Сумма по горизонтали
    table['vi_sum'] = table.sum(axis=1)

    # Сумма по вертикали
    vj_sum = pd.Series(name='vj_sum')
    table = table.append(vj_sum, ignore_index=False)
    table.iloc[4] = table.sum(axis=0)

    print("3.1\nВыведем таблицу сопряженности двух признаков")
    print(table)

    # Статистика критерия независимости по формуле из расчетника
    statistic_sum = 0
    for i in range(4):
        for j in range(4):
            statistic_sum += np.power(table.iloc[j][i], 2) /
(table.iloc[4][i] * table.iloc[j][4])
    statistic_practic = (statistic_sum - 1) * 50

    # Табличное значение
```

```
    statistic_theory = 16.9

    if statistic_theory > statistic_practic:
        print('\nПеременные независимы, т.к', statistic_practic, '<',
statistic_theory)
    else:
        print('\nПеременные зависимы, т.к', statistic_practic, '>=',
statistic_theory)
```

Вывод:

```
3.1
Выведем таблицу сопряженности двух признаков
                (4.899, 5.6]  (5.6, 5.9]  (5.9, 6.3]  (6.3, 7.0]  vi_sum
lenght_of_petal
(2.999, 4.0]            11.0         3.0         2.0         0.0    16.0
(4.0, 4.35]              2.0         5.0         1.0         1.0     9.0
(4.35, 4.6]              3.0         1.0         5.0         5.0    14.0
(4.6, 5.1]               0.0         1.0         5.0         5.0    11.0
vj_sum                  16.0        10.0        13.0        11.0    50.0

Переменные зависимы, т.к 30.494498793504476 >= 16.9
```

3.2. Вычислить оценку ковариации, коэффициента корреляции

Проверить гипотезу о незначимости коэффициента корреляции

Используемые формулы:

$$r_{xy} = \frac{s_{xy}}{s_x s_y},$$

где $s_{xy} = \overline{xy} - \overline{x} \cdot \overline{y}$ - выборочный коэффициент ковариации;

$$\overline{xy} = \frac{1}{n}\sum_{i=1}^{n} x_i y_i \,,\; s_x^2 = \overline{x^2} - (\overline{x})^2 \,,\; s_y^2 = \overline{y^2} - (\overline{y})^2$$

$$\overline{x^2} = \frac{1}{n}\sum_{i=1}^{n} (x_i)^2 \,,\; \overline{y^2} = \frac{1}{n}\sum_{i=1}^{n} (y_i)^2 \,,$$

$s_x = \sqrt{s_x^2}$ и s_y - выборочное стандартное отклонение,

$\overline{y}, \overline{x}$ - выборочные средние.

0 , X,Y

Распределение статистики

$$T = \frac{r}{\sqrt{1-r^2}}\sqrt{n-2}$$

при нормально распределенных X, Y и достаточно больших n описывается распределением Стьюдента t_{n-2}.

Таким образом, H_0 отвергается на уровне значимости α, если

$$|T_{набл}| > t_{кр}(\alpha, n-2).$$

3.2 Линейная регрессия

КОД:

```
def task2(width_petal, width_sepal):
    m_len = width_petal.mean() # Мат ожидание
    m_width = width_sepal.mean()
    alpha = 0.05  # Предполагаем такое значение

    xy = np.sum(np.multiply(width_petal, width_sepal))  # сумма произведений
    xy_m = xy / 50  # среднее от произведения переменных

    s_len = np.sum(np.power(np.subtract(width_petal, m_len), 2))  # сумма
дисперсий лепестка
    s_len_m = s_len / 50

    s_width = np.sum(np.power(np.subtract(width_sepal, m_width), 2))  # сумма
дисперсий чашелистника
    s_width_m = s_width / 50

    std_dev_len = np.sqrt(s_len_m)
    std_dev_width = np.sqrt(s_width_m)

    c = xy_m - m_len * m_width
    r = c / (std_dev_len * std_dev_width)

    print("3.2\nКоэффициент корреляции:", r)
    print("Коэффициент ковариации:", c)

    T = (r / np.sqrt(1 - r ** 2)) * (np.sqrt(50 - 2))
    tss = s_width

    # T табличное
    T_table = 1.96

    if T > T_table:
        print("Гипотеза о незначимости не принимается\n\n")
```

Вывод:

```
3.2
Коэффициент корреляции: 0.7540489585920163
Коэффициент ковариации: 0.17924000000000007
Гипотеза о незначимости не принимается
```

3.3. Оценить параметры линейной регрессии, вычислить коэффициент детерминации, проверить значимость модели по критерию Фишера.

Создаем LinearRegression модель и обучаем ее.

Формулы:

Остаточная вариация (residual sum of squares)

$$RSS = \sum_{i=1}^{n} (e_i)^2 ;$$

Стандартная ошибка (несмещенная оценка дисперсии ошибки):

$$s^2 = RSS / (n - m - 1),$$

где $m = 1$ - число независимых переменных.

Общая вариация

$$TSS = \sum_{i=1}^{n} (y_i - \overline{y})^2 ;$$

Вариация, объясненная регрессией

$$ESS = \sum_{i=1}^{n} (\hat{y}_i - \overline{y})^2 .$$

Коэффициент детерминации $R^2 = 1 - RSS/TSS = ESS/TSS; \quad R^2 \in [0,1]$

```
x = length1.values.reshape(-1, 1)
y = length2.values.reshape(-1, 1)
reg = LinearRegression()
reg.fit(x, y)
plt.scatter(length1, length2)
plt.plot(length1, reg.predict(x), color='red', linewidth=2)
plt.show()
print("Уравнение линейной регрессии: Y = {:.5} +
{:.5}X".format(reg.intercept_[0], reg.coef_[0][0]))

m_len = length2.mean() # Мат ожид
m_width = length1.mean()
xy = np.sum(np.multiply(length2, length1))  # сумма произведений
xy_m = xy / 50  # среднее от произведения переменных

tss = np.sum(np.power(np.subtract(length1, m_width), 2))  # сумма дисперсий

sq_len = np.sum(np.power(length2, 2))
beta1_lid = (xy_m - m_len * m_width) / ((sq_len / 50) - (m_len ** 2))
beta0_lid = m_width - beta1_lid * m_len

rss = 0
ess = 0
for i in range(50, 100):
    y_lid = beta0_lid + beta1_lid * length2[i]
    rss += (length1[i] - y_lid) ** 2
```

```
    ess += (y_lid - m_width) ** 2

print("tss", tss)
print("rss", rss)
print("ess", ess)
determ_ko = 1 - rss / tss
print("Коэффициент детерминации по формуле 1 - rss/tss", determ_ko)

determ_ko2 = ess / tss
print("Коэффициент детерминации по формуле ess/tss", determ_ko2)
determ_ko3 = r * r
print("Коэффициент детерминации по формуле r*r", determ_ko3)

f = (determ_ko3 / (1 - determ_ko3)) * ((50 - 1 - 1) / 1)
f_table = 4.03
if f_table > f:
    print("регрессия считается незначимой, т.к", f_table, '>', f)
else:
    print("регрессия считается значимой, т.к", f_table, '<=', f)
```

Вывод:

```
Уравнение линейной регрессии: Y = 2.4075 + 0.82828X
tss 10.820000000000002
rss 4.667858018260922
ess 6.1521419817389305
Коэффициент детерминации по формуле 1 - rss/tss 0.5685898319537042
Коэффициент детерминации по формуле ess/tss 0.5685898319536903
Коэффициент детерминации по формуле r*r 0
регрессия считается незначимой, т.к 4.03 > 0.0
```

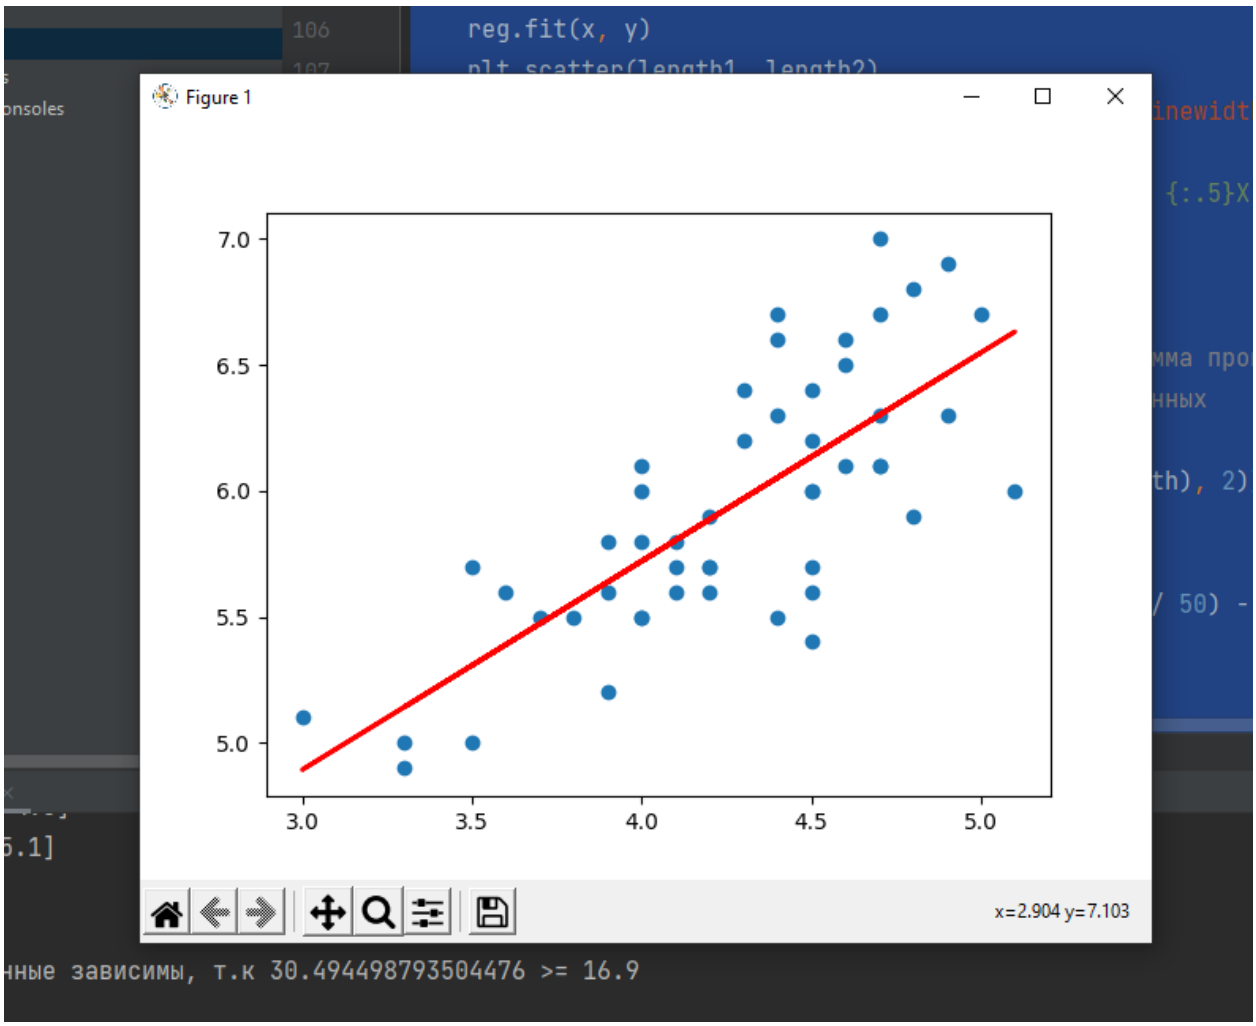
reg.fit(x, y)
Figure 1
7.0
6.5
6.0
5.5
5.0
3.0
3.5
4.0
4.5
5.0
x=2.904 y=7.103
нные зависимы, т.к 30.494498793504476 >= 16.9